

Inteligencia artificial avanzada para la ciencia de datos II(Módulo 5: Estadística Avanzada para ciencia de datos)


Roel De la Rosa - A01197595

21/11/2022

A través de este reporte se realizará un análisis de series no estacionarias. El objetivo es realizar un análisis de series de tiempo para una tienda de televisores, se busca predecir la cantidad de ventas que se harán para su siguiente año.

Para poder hacerlo primero se hará una descomposición de series temporales, lo que ocurre aquí es que se separa una serie de tiempo en tres componentes distintos. El primero de ellos es la tendencia que tiene la serie de tiempo, el segundo es el componente estacional el cual es un fenómeno cíclico. El tercero es el componente aleatorio, el cual es el factor necesario para que, sumado a los dos anteriores, se llegue a la observación real.


Realiza el gráfico de dispersión. Observa la tendencia y los ciclos.



Realiza el análisis de tendencia y estacionalidad

```
## $x
##   Qtr1 Qtr2 Qtr3 Qtr4
## 1  4.8  4.1  6.0  6.5
## 2  5.8  5.2  6.8  7.4
## 3  6.0  5.6  7.5  7.8
## 4  6.3  5.9  8.0  8.4
##
## $seasonal
##       Qtr1       Qtr2       Qtr3       Qtr4
## 1 0.9306617 0.8363763 1.0915441 1.1414179
## 2 0.9306617 0.8363763 1.0915441 1.1414179
## 3 0.9306617 0.8363763 1.0915441 1.1414179
## 4 0.9306617 0.8363763 1.0915441 1.1414179
##
## $trend
##       Qtr1       Qtr2       Qtr3       Qtr4
## 1      NA      NA 5.4750 5.7375
## 2 5.9750 6.1875 6.3250 6.4000
## 3 6.5375 6.6750 6.7625 6.8375
## 4 6.9375 7.0750      NA      NA
##
## $random
##       Qtr1       Qtr2       Qtr3       Qtr4
## 1      NA      NA 1.0039818 0.9925353
## 2 1.0430335 1.0048157 0.9849340 1.0129944
## 3 0.9861607 1.0030787 1.0160445 0.9994305
## 4 0.9757661 0.9970658      NA      NA
##
## $figure
## [1] 0.9306617 0.8363763 1.0915441 1.1414179
##
## $type
## [1] "multiplicative"
##
## attr(,"class")
## [1] "decomposed.ts"
```

Decomposition of multiplicative time series




Aquí podemos ver la descomposición

de la serie temporal. La primera gráfica, 'observed', muestra los resultados reales que se obtienen. El segundo, 'trend', muestra la línea de tendencia de los datos obtenidos. La tercera gráfica, 'seasonal', muestra las variaciones periódicas que se observan del comportamiento de los datos reales. Por último, la última gráfica muestra el comportamiento 'random', es decir, que no se puede predecir. Esto es importante pues nunca tendremos un modelo que puede predecir todo de forma perfecta.

Analiza el modelo lineal de la tendencia:

Realiza la regresión lineal de la tendencia (ventas desestacionalizadas vs tiempo)

Dibuja la recta junto con las ventas desestacionalizadas.



Podemos observar que las ventas


desestacionalizadas parece que se comporte de manera lineal con respecto al tiempo. Si bien la línea no es perfecta, parece que se ajusta de manera más que adecuada con las ventas desestacionalizadas.

Analiza la pertinencia del modelo lineal:

```
##
## Call:
## lm(formula = ventas_desestacionalizadas ~ t)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5007 -0.1001  0.0037  0.1207  0.3872
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.10804    0.11171  45.73  < 2e-16 ***
## t            0.14738    0.01155  12.76 4.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.213 on 14 degrees of freedom
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9151
## F-statistic: 162.7 on 1 and 14 DF, p-value: 4.248e-09
```

A partir de análisis de la regresión lineal de las ventas desestacionalizadas podemos observar que el p-value es de 4.248×10^{-9} , lo cual indica que el modelo es estadísticamente significativo, es decir, la regresión lineal representa la tendencia de los datos.

Normal Q-Q Plot



```
##  
## Shapiro-Wilk normality test  
##  
## data:  lr$residuals  
## W = 0.96379, p-value = 0.7307
```

Podemos ver que parece ser que no se rechaza la prueba de normalidad de shapiro con respecto a los residuales de la regresión lineal. Esto es importante, pues para poder justificar que una regresión lineal se ajusta correctamente debemos de comprobar que los residuales de dicha regresión lineal se distribuyen bajo una distribución Gaussiana.

Calcula el CME y el EPAM (promedio de los errores porcentuales) de la predicción de la serie de tiempo.


Posteriormente realizamos unas predicciones para una serie de tiempo y podemos ver a continuación los resultados obtenidos

```
e <- NA  
p <- NA  
n <- 16  
error <- NA  
y = function(k) {5.108 + 0.147*k}  
  
for(i in 1:(n-3)){p[i+3]=y(i); e[i+3] = p[i+3] - ventas[i+3]; error[i+3] = ((ventas[i+3]-p[i+3])/ventas[i+3])*100  
}  
CME2 <-mean(e^2,na.rm=TRUE)  
message('El CME^2 es de: ', round(CME2,5))
```

```
## El CME^2 es de: 1.004
```

Vemos que el CME² obtenido es de 1.004, el cual es un valor relativamente muy bajo, lo que puede indicar que la estimación que hemos elaborado podrían ser consideradas como adecuadas.

Dibuja el gráfico de los valores de las ventas y las predicciones vs el tiempo



En el gráfico anterior podemos

observar que la línea recta se ajusta muy bien a los datos, lo cual nos indica nuevamente que los resultados obtenidos son bastante buenos.

Realiza el pronóstico para el siguiente año.

```
## Trimestres predicciones
## 1      1      7.079544
## 2      2      6.485262
## 3      3      8.624290
## 4      4      9.186131
```

A partir de lo anteriormente mencionado se realiza las predicciones para los siguientes trimestres y podemos observar los resultados obtenidos. Obviamente no se pueden vender un número no entero de televisores, por lo que, en un caso pesimista, redondeamos al entero menor más cercano.

```
## Trimestres predicciones
## 1      1      7
## 2      2      6
## 3      3      8
## 4      4      9
```

Loading [MathJax]/jax/output/HTML-CSS/jax.js